

MACHINE LEARNING · WINE QUALITY DATASET

Previsão de Qualidade do Vinho com Machine Learning

Uma análise físico-química para apoiar decisões de qualidade na produção de vinho tinto. Do dado bruto ao modelo preditivo.

Apresentação Executiva · Tech Challenge · Grupo 18

Contexto e Objetivo de Negócio

O Wine Quality Dataset reúne medições físico-químicas de amostras de vinho tinto, acidez, açúcar residual, cloretos, dióxido de enxofre, densidade, pH, sulfatos e teor alcoólico, associadas a uma nota de qualidade sensorial (0 a 10) atribuída por avaliadores.

Objetivo de negócio: identificar quais características físico-químicas estão associadas a vinhos de melhor qualidade, apoiando produtores e enólogos em ajustes de processo e em uma triagem mais objetiva. Reduzindo a dependência exclusiva da avaliação sensorial manual.

1.143

amostras de vinho tinto

12

variáveis originais (11 físico-químicas + Id)

0-10

escala original de qualidade sensorial

2

classes de negócio após corte binário

Da Nota à Decisão: Variável-Alvo Binária

Critério adotado: `quality_binary = 1` ("bom") quando `quality ≥ 6`; caso contrário, 0 ("regular/ruim").

A

Tamanho de amostra

Com corte ≥ 7 , apenas 13,9% das amostras ficariam na classe positiva — poucos exemplos para treinar e validar com confiança.

B


Balanceamento adequado

Com corte ≥ 6 , a proporção fica em 54,3% vs. 45,7%, próxima do equilíbrio — permite comparar modelos sem reamostragem artificial.

C

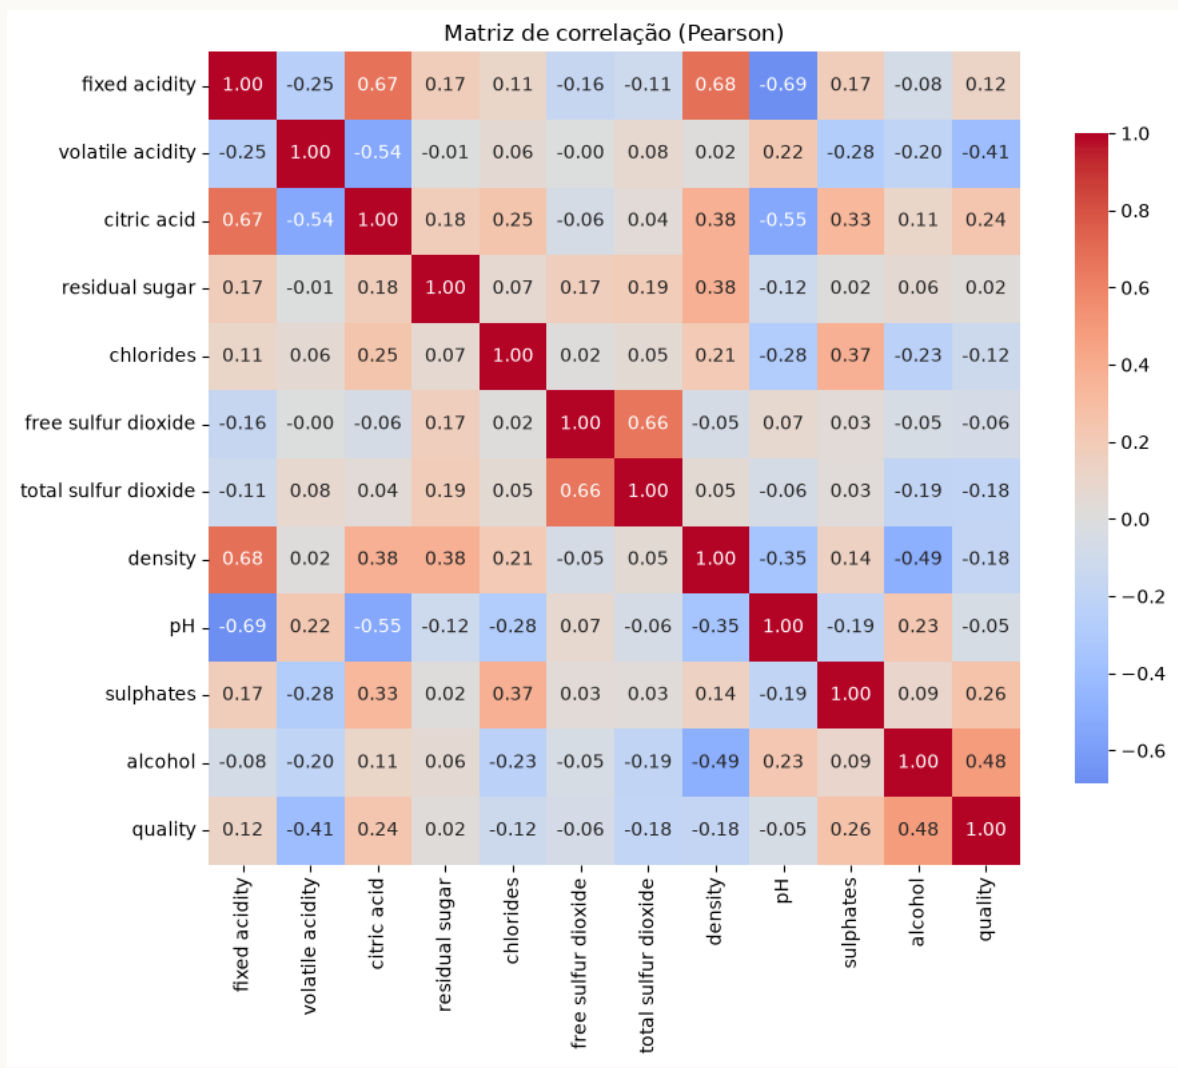
Sentido prático

A nota 6 é a mediana/moda da distribuição de `quality` neste conjunto, um limiar natural de "aprovação".



Corte adotado (≥ 6): 54,3% bom vs. 45,7% regular — leve desbalanceamento, tratável sem SMOTE/undersampling.

O Que Explica a Qualidade? Correlações



+0,48

álcool correlação positiva mais forte — maior teor alcoólico tende a receber notas mais altas.

-0,41

acidez volátil correlação negativa mais forte — associada a defeitos sensoriais no vinho.

+0,25

sulfatos segunda maior correlação positiva com a qualidade.

+0,23

ácido cítrico correlação positiva moderada com a qualidade.

Preparação dos Dados

1

Valores faltantes

Nenhum valor nulo identificado nas 12 colunas originais — nenhuma imputação foi necessária.

2

Duplicatas

125 linhas (10,9%) com medições idênticas foram mantidas — representam amostras/lotas válidos, não erro de coleta.

3

Normalização

Variáveis padronizadas com StandardScaler antes de KNN e SVM, sensíveis à escala.

4

Dois conjuntos de features

Todas as 11 variáveis físico-químicas vs. as 4 mais correlacionadas (álcool, acidez volátil, sulfatos, ácido cítrico) — testados em paralelo.

Modelos Testados: KNN e SVM

Cada algoritmo foi treinado e avaliado em dois cenários — com as 11 variáveis físico-químicas e com as 4 de maior correlação — em uma tarefa de classificação binária (bom vs. regular/ruim).



KNN — K-Nearest Neighbors

Classifica cada vinho pela maioria entre seus vizinhos mais próximos no espaço de variáveis normalizadas. Hiperparâmetro k ajustado por curva de erro.

Baseline (aprovar todos): 54,1% de acurácia



SVM — Support Vector Machine

Busca o hiperplano (kernel RBF) que melhor separa vinhos bons de regulares, maximizando a margem entre as classes.

Baseline (aprovar todos): 54,1% de acurácia


Comparação de Desempenho dos Modelos

Modelo	Acurácia	Precisão	Recall	F1	AUC	FP	FN
KNN (11 features)	78,6%	78,6%	83,1%	0,808	0,857	28	21
KNN (4 features)	80,3%	79,7%	85,5%	0,825	0,873	27	18
SVM (11 features)	78,6%	79,5%	81,5%	0,805	0,842	26	23
SVM (4 features)	77,7%	80,2%	78,2%	0,792	0,838	24	27

Baseline (classificar todos os vinhos como "bom"): 54,1% de acurácia no conjunto de teste — todos os cenários ficam bem acima dela.

Melhor cenário global: KNN com 4 features — maior acurácia (80,3%), maior AUC (0,873) e maior F1 (0,825). A diferença entre o melhor e o pior modelo equivale a apenas 6 vinhos em 229 no teste — uma vantagem pequena para uma única divisão treino/teste.

Curva ROC: Capacidade de Separar as Classes



KNN — 4 features

0,873


AUC

O AUC (0,873) supera a acurácia (0,803), indicando que o modelo ordena bem os vinhos por qualidade, mas o limiar padrão de 0,5 não é o corte ótimo — ajustá-lo pode melhorar o resultado sem trocar de algoritmo.

Todos os 4 cenários (KNN e SVM × 11 e 4 features) ficam entre 0,838 e 0,873 de AUC — bem acima de 0,5 (aleatório), confirmando boa separação das classes em todos eles.


Perfil de Erro: Permissivo x Conservador

Com acurácias próximas, os dois algoritmos erram de formas opostas — a escolha do modelo passa a ser uma decisão de negócio, não estatística.



KNN (4 features) — permissivo

Aprovou 27 vinhos regulares como bons (FP), mas reprovou só 18 vinhos bons (FN). Maior recall (85,5%) — deixa passar poucos bons lotes.



SVM (4 features) — conservador

Menor número de aprovações erradas (24 FP), maior precisão (80,2%), mas reprova 27 vinhos bons (FN) — o pior recall (78,2%).

Recomendações para o Processo de Produção

1

Triagem ampla

Para não perder lotes de boa qualidade (com validação sensorial posterior), usar KNN com 4 features — maior recall e melhor desempenho global.

2

Certificação/premium

Para garantir que o rótulo de alta qualidade seja confiável, preferir SVM com 4 features — menor taxa de aprovação indevida.

3

Monitoramento de lotes

Acompanhar álcool, acidez volátil, sulfatos e ácido cítrico como indicadores de controle de qualidade — reduz custo e tempo de análise laboratorial (4 em vez de 11 variáveis) sem perda prática de desempenho preditivo.

Limitações e Próximos Passos

O que observar com cautela

- 125 linhas duplicadas (10,9%) foram mantidas na base — podem tornar as métricas do KNN levemente otimistas, já que amostras idênticas podem cair simultaneamente em treino e teste.
- A diferença entre o melhor e o pior modelo (2,6 p.p. de acurácia) equivale a apenas 6 vinhos em 229 — pequena demais para ser decisiva com uma única divisão treino/teste.
- Importância de variáveis (Random Forest) indica contribuição preditiva, não causalidade.

Recomendações de continuidade

- Validar os modelos com dados reais e independentes do processo produtivo antes de qualquer uso operacional.
- Ajustar o limiar de decisão (threshold), já que em todos os cenários o AUC supera a acurácia com corte padrão de 0,5.
- Testar validação cruzada (k-fold) para confirmar a estabilidade das métricas além de uma única divisão treino/teste.

Obrigada

Tech Challenge — Previsão de Qualidade do Vinho com Machine Learning