



Faculdade de Informática e Administração Paulista

POSTECH

Pós-Graduação em Data Analytics

Fase 2 — Tech Challenge

TECH CHALLENGE

Wine Quality Dataset

Classificação Binária da Qualidade de Vinhos com KNN e SVM

Elaine Hernandes – RM 375521

Isabela Bersan Mariano Pádua – RM 374811

Laura Garcias Barreto Soares dos Santos – RM 373850

Lidiany Christiany da Silva – RM 374699

Turma: 14DTAT_grupo:18

Sumário

Introdução	1
Objetivo	2
Objetivo Geral	2
Objetivos Específicos	2
Base de Dados.....	2
Análise Exploratória de Dados (EDA)	3
Distribuição da Variável Qualidade	3
Correlação entre as Variáveis	3
Boxplots	4
Pré-processamento dos Dados	7
Remoção da Variável ID	7
Criação da Variável de Classificação	7
Separação entre Variáveis Preditivas e Variável-Alvo	8
Separação entre Treino e Teste.....	8
Normalização dos Dados	8
Duas Versões das Variáveis	8
Modelagem.....	9
Estratégia da Modelagem	9
Modelo KNN	10
KNN com 11 Variáveis	10
KNN com 4 Variáveis	11
Modelo SVM.....	12
SVM com 11 Variáveis	12
SVM com 4 Variáveis	12
Matriz de Confusão do SVM	13
Comparação dos Modelos	14
KNN x SVM	14
Importância das Variáveis na Previsão da Qualidade	15

Importância das Variáveis	15
Comparação com a Análise de Correlação	16
Implicações para Produção	16
Escolha do Algoritmo	17
Conclusão	17
Referências	18
Apêndice A – GitHub	19
Apêndice B – Vídeo YouTube	19

Introdução

A qualidade de um vinho está relacionada a diferentes características físico-químicas que podem ser medidas durante o processo de produção. Entre essas características estão acidez, açúcar residual, cloretos, dióxido de enxofre, densidade, pH, sulfatos e teor alcoólico.

Neste trabalho, foi utilizado um conjunto de dados de vinhos tintos contendo informações físico-químicas das amostras e uma avaliação de qualidade atribuída por avaliadores. A variável *quality* apresenta notas entre 3 e 8 no conjunto analisado.

O objetivo da análise é identificar quais características dos vinhos apresentam maior relação com a qualidade e verificar se modelos de Machine Learning são capazes de classificar os vinhos em duas categorias: regular/ruim e bom.

Inicialmente foi realizada uma análise exploratória dos dados, buscando compreender a distribuição das variáveis, identificar possíveis valores atípicos e verificar relações entre as características físico-químicas e a qualidade. Após esta análise, foram aplicadas técnicas de pré-processamento e modelos de classificação, permitindo comparar diferentes abordagens e avaliar seus resultados.

A análise também busca identificar quais variáveis apresentam maior importância para a previsão da qualidade, podendo contribuir para uma melhor compreensão dos fatores associados à classificação dos vinhos.

Objetivo

Objetivo Geral

Analisar as características físico-químicas de vinhos tintos e desenvolver modelos de Machine Learning capazes de classificar as amostras de acordo com sua qualidade.

Objetivos Específicos

- Explorar e compreender as características presentes no conjunto de dados;
- verificar a existência de valores ausentes, duplicidades e possíveis outliers;
- analisar a relação entre as características físico-químicas e a variável de qualidade;
- transformar a variável *quality* em uma classificação binária;
- realizar o pré-processamento dos dados para utilização nos modelos;
- comparar o desempenho dos modelos KNN e SVM;
- avaliar os modelos utilizando diferentes métricas de desempenho;
- identificar as variáveis com maior importância para a previsão da qualidade;
- analisar os resultados e suas possíveis aplicações no controle de qualidade dos vinhos.

Base de Dados

Os dados utilizados neste trabalho foram obtidos na plataforma Kaggle (referência completa na seção 11). O conjunto de dados Wine Quality Dataset possui 1.143 registros e 13 colunas. As variáveis são compostas principalmente por características físico-químicas dos vinhos, além da variável *quality*, que

representa a avaliação de qualidade, e da coluna Id, utilizada apenas como identificador das amostras.

As características físico-químicas analisadas foram: acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e álcool.

Durante a análise exploratória, não foram encontrados valores ausentes e analisando se havia duplicidade na base, inicialmente não foram identificados registros duplicados quando todas as colunas da base eram consideradas, porém, como a coluna Id representa apenas um identificador da amostra, ela foi retirada da análise. Após essa remoção, foram identificados 125 registros com características físico-químicas e qualidade idênticas, correspondendo a aproximadamente 10,9% da base.

Antes da modelagem, a coluna Id foi removida, pois representa apenas um identificador, sem significado relacionado às características do vinho.

Análise Exploratória de Dados (EDA)

O objetivo durante a análise exploratória, foi compreender melhor a distribuição dos dados e verificar possíveis relações entre as características físico-químicas e a qualidade dos vinhos.

Distribuição da Variável Qualidade

A variável *quality* foi analisada para compreender a distribuição das avaliações presentes na base. Verificou que notas variam de 3 a 8. Para a construção dos modelos de classificação, a variável foi posteriormente transformada em uma variável binária, considerando vinhos com nota menor que 6 como Regular/Ruim e vinhos com nota igual ou superior a 6 como Bom.

Após essa transformação, foram obtidos 621 vinhos classificados como Bom, correspondendo a 54,3% da base, e 522 classificados como Regular/Ruim, correspondendo a 45,7%. A distribuição das classes ficou relativamente equilibrada, não apresentando uma diferença muito grande entre os dois grupos.

Correlação entre as Variáveis

A matriz de correlação foi utilizada para verificar a relação entre as variáveis físico-químicas e a qualidade dos vinhos. Entre as variáveis analisadas,

o teor alcoólico apresentou a maior correlação positiva com a qualidade, com valor de 0,48 conforme pode ser verificado na figura 1. Isso indica uma tendência de que vinhos com maior teor alcoólico apresentem maiores avaliações de qualidade.




Figura 1 – Matriz de Correlação de Pearson

Boxplots

O boxplot do teor alcoólico, conforme Figura 2, mostra uma diferença entre as duas classes. Os vinhos classificados como Bom apresentam, em geral, valores de álcool superiores aos vinhos classificados como Regular/Ruim. Na classe Regular/Ruim, os valores se concentram aproximadamente entre 9,5 e 11, enquanto na classe Bom os valores se concentram aproximadamente entre 11 e 12,5. Foram observados valores considerados outliers na classe Regular/Ruim, acima de 13.




Figura 2 – Gráfico de Boxplot (Alcohol)

Para a acidez volátil, observa-se uma tendência inversa à encontrada para o álcool. Observa na Figura 3 que os vinhos classificados como Regular/Ruim apresentam valores geralmente maiores, aproximadamente entre 0,4 e 0,6, enquanto os vinhos classificados como Bom apresentam valores aproximadamente entre 0,3 e 0,45. Também foram observados valores atípicos nas duas classes.




Figura 3 – Gráfico de Boxplot (Volatile Acidity)

Na variável sulfatos demonstrado na Figura 4, observa que os vinhos classificados como Bom apresentam uma tendência de valores ligeiramente maiores. A classe Regular/Ruim apresenta concentração aproximadamente entre 0,5 e 0,75, enquanto a classe Bom apresenta valores aproximadamente entre 0,7 e 0,8. Também foram identificados valores atípicos nas duas classes.




Figura 4 – Gráfico de Boxplot (Sulphates)

Para o ácido cítrico, observa-se que os vinhos classificados como Bom apresentam, em geral, valores maiores, demonstrado na Figura 5. A classe Regular/Ruim apresenta valores aproximadamente entre 0,1 e 0,4, enquanto a classe Bom apresenta valores aproximadamente entre 0,3 e 0,5. Apesar dessa tendência, existe sobreposição entre as duas classes.




Figura 5 – Gráfico de Boxplot (Citric Acid)

A análise exploratória mostrou diferenças na distribuição das características físico-químicas entre as classes de qualidade. O teor alcoólico apresentou uma tendência de valores maiores nos vinhos classificados como Bom, enquanto a acidez volátil apresentou tendência contrária. Sulfatos e ácido cítrico também apresentaram valores geralmente maiores na classe Bom, porém com maior sobreposição entre as classes. Esses resultados são consistentes

com as correlações observadas e indicam que essas características podem contribuir para a classificação da qualidade dos vinhos.

Pré-processamento dos Dados

Este capítulo explicará as alterações feitas na base antes de aplicar os algoritmos de Machine Learning


Remoção da Variável ID

A variável *Id* foi removida do conjunto de dados, pois representa apenas um identificador das amostras e não possui relação direta com as características físico-químicas utilizadas para classificar a qualidade dos vinhos. A permanência dessa variável poderia adicionar uma informação sem significado para o modelo e, por isso, ela não foi utilizada como variável preditora.

Criação da Variável de Classificação

Para possibilitar a aplicação dos modelos de classificação, a variável original *quality* foi transformada em uma variável binária denominada *quality_binary*. Foram considerados como “Bom” os vinhos com qualidade maior ou igual a 6, enquanto os vinhos com qualidade inferior a 6 foram classificados como “Regular/Ruim”.

Essa transformação permitiu simplificar o problema, passando de uma previsão de diferentes níveis de qualidade para uma classificação em duas categorias.



Separação entre Variáveis Preditivas e Variável-Alvo

Após a definição da variável-alvo, os dados foram separados em duas partes. A variável *quality_binary* foi definida como variável resposta (y), enquanto as características físico-químicas dos vinhos foram utilizadas como variáveis preditoras (X).

Assim, o objetivo dos modelos foi utilizar as características físico-químicas disponíveis para classificar cada vinho como “Bom” ou “Regular/Ruim”.

Separação entre Treino e Teste

Os dados foram divididos em dois conjuntos: 80% para treinamento e 20% para teste.

Durante a divisão foi utilizado o parâmetro *stratify*, com o objetivo de preservar nos dois conjuntos uma proporção semelhante entre as classes “Bom” e “Regular/Ruim”. Essa estratégia é importante para evitar que a divisão dos dados resulte em uma representação muito diferente das classes entre treinamento e teste.

Normalização dos Dados

Como as variáveis possuem diferentes escalas de valores, foi realizada a padronização dos dados antes da aplicação dos modelos. Essa etapa é especialmente importante para algoritmos como KNN e SVM, que podem ser influenciados pela escala das variáveis.

A padronização colocar as características em uma escala comparável, evitando que uma variável tenha maior influência no modelo apenas por apresentar valores numericamente maiores.

A transformação foi ajustada utilizando os dados de treinamento e posteriormente aplicada aos dados de teste, evitando que informações do conjunto de teste fossem utilizadas durante o treinamento.

Duas Versões das Variáveis

Além da utilização de todas as características disponíveis, foi realizada uma segunda abordagem utilizando apenas quatro variáveis: *alcohol*, *volatile acidity*, *sulphates* e *citric acid*.

A escolha dessas variáveis foi motivada pelos resultados observados durante a análise exploratória, que indicaram diferenças na distribuição dessas características entre as classes de qualidade e relações relevantes com a variável de qualidade.

Dessa forma, foi possível comparar o desempenho dos modelos utilizando todas as variáveis disponíveis com uma abordagem mais simples, baseada em um conjunto reduzido de características.

Modelagem

Estratégia da Modelagem

Após o pré-processamento dos dados, foram utilizados dois algoritmos de classificação de famílias diferentes: K-Nearest Neighbors (KNN) e Support Vector Machine (SVM).

A escolha desses algoritmos permitiu comparar duas formas diferentes de classificação. O KNN realiza a classificação com base na proximidade entre as amostras, enquanto o SVM busca estabelecer uma fronteira de separação entre as classes.

Para avaliar o impacto da quantidade de variáveis utilizadas, cada algoritmo foi testado em dois cenários: utilizando as 11 variáveis físico-químicas disponíveis e utilizando apenas as 4 variáveis que apresentaram maior correlação com a qualidade, sendo elas *alcohol*, *volatile acidity*, *sulphates* e *citric acid*.

Foram avaliados quatro cenários diferentes, permitindo verificar não apenas qual algoritmo apresentou melhor desempenho, mas também se a redução do número de variáveis poderia manter ou melhorar os resultados.

Modelo KNN

O primeiro algoritmo utilizado foi o K-Nearest Neighbors (KNN). Esse método classifica uma nova amostra considerando a proximidade entre ela e as amostras existentes no conjunto de treinamento.

Foram testados diferentes valores de K para observar o comportamento do erro do modelo. Em seguida, foi utilizada a técnica GridSearchCV, com validação cruzada de 5 folds, para buscar uma combinação mais adequada dos hiperparâmetros. Foram avaliados diferentes valores para o número de vizinhos, pesos das observações e métricas de distância. A acurácia foi utilizada como critério para selecionar a melhor combinação de hiperparâmetros.

KNN com 11 Variáveis

Com o cenário de 11 variáveis físico-químicas, o GridSearchCV selecionou 9 vizinhos, utilizando a distância *cosine* e o peso *distance*. O modelo foi então treinado com esses parâmetros e avaliado utilizando o conjunto de teste.

Neste cenário o KNN apresentou acurácia de 78,6%, resultado superior à baseline de aproximadamente 54,2%, que corresponde à classificação de todos os vinhos como pertencentes à classe Bom.

A curva ROC, conforme a figura 7, apresentou AUC de 0,857, indicando uma boa capacidade do modelo de diferenciar as duas classes.




Figura 7 – Curva ROC – KNN com 11 variáveis

KNN com 4 Variáveis

Em seguida, o KNN foi treinado utilizando apenas as quatro variáveis que apresentaram maior correlação com a qualidade: álcool, acidez volátil, sulfatos e ácido cítrico. Com esta redução, o KNN apresentou uma pequena melhora em seu desempenho, passando de 78,6% para 80,3% de acurácia. O AUC também aumentou de 0,857 para 0,873.




Figura 8 – Curva ROC – KNN com 4 variáveis

A matriz de confusão mostrou que o KNN com quatro variáveis apresentou maior quantidade de falsos positivos do que falsos negativos. Foram classificados como bons 27 vinhos que pertenciam à classe “Regular/Ruim”, enquanto 18 vinhos realmente bons foram classificados como “Regular/Ruim”.




Figura 9 – Matriz de Confusão – KNN com 4 variáveis

Esse comportamento indica que o modelo é relativamente permissivo, pois tende a classificar mais vinhos como bons. Esse comportamento também está relacionado ao seu maior recall, de aproximadamente 85,5%, indicando que o modelo conseguiu identificar a maior parte dos vinhos realmente bons.

Modelo SVM

O segundo algoritmo utilizado foi o Support Vector Machine (SVM). O modelo foi configurado utilizando o kernel RBF, que permite representar relações não lineares entre as variáveis. Assim como no KNN, os hiperparâmetros foram selecionados utilizando o GridSearchCV, com validação cruzada de 5 folds e acurácia como métrica de seleção. Foram avaliadas diferentes combinações dos parâmetros C e gamma, mantendo o kernel RBF.

SVM com 11 Variáveis

Utilizando as 11 variáveis físico-químicas, o SVM apresentou acurácia de 78,6%, resultado semelhante ao KNN com as mesmas variáveis. A curva ROC apresentou AUC de 0,842, indicando boa capacidade de separação entre as classes e desempenho superior à classificação aleatória.




Figura 10 – Curva ROC – SVM com 11 variáveis

SVM com 4 Variáveis

Quando foram utilizadas apenas as quatro variáveis seleccionadas, o SVM apresentou acurácia de 77,7%, representando uma pequena redução em relação ao modelo utilizando as 11 variáveis, que apresentou 78,6%.




Figura 11 – Curva ROC – SVM com 4 variáveis

O AUC também apresentou pequena redução, passando de 0,842 para 0,838. Portanto, diferentemente do KNN, a redução das variáveis não trouxe melhora para o SVM neste conjunto de dados.

Matriz de Confusão do SVM

O SVM apresentou um comportamento diferente do KNN. Utilizando quatro variáveis, foram identificados 24 falsos positivos, enquanto 27 vinhos bons foram classificados incorretamente como “Regular/Ruim”.




Figura 12 – Matriz de Confusão – SVM com 4 variáveis

Dessa forma, o SVM apresentou um comportamento mais conservador, pois foi mais restritivo ao classificar um vinho como “Bom”. Esse comportamento resultou em menor quantidade de falsos positivos, mas também em maior quantidade de falsos negativos.

Comparação dos Modelos

A comparação dos quatro cenários mostrou resultados relativamente próximos. A acurácia variou entre 77,7% e 80,3%, enquanto o AUC variou entre 0,838 e 0,873.

Modelo	Variáveis	Acurácia	AUC	F1
KNN	11	78,60%	0,857	—
KNN	4	80,30%	0,873	0,825
SVM	11	78,60%	0,842	—
SVM	4	77,70%	0,838	—

Figura 13 – Comparação dos Modelos

O melhor desempenho geral foi obtido pelo KNN utilizando as quatro variáveis selecionadas, com acurácia de 80,3%, AUC de 0,873 e F1 de 0,825. Apesar disso, a diferença entre os modelos não é muito grande. A diferença entre o melhor e o pior resultado de acurácia foi de 2,6 pontos percentuais, equivalente

a aproximadamente seis vinhos no conjunto de teste de 229 amostras. Portanto, considerando que foi utilizada uma única divisão entre treinamento e teste, essa diferença não deve ser interpretada como uma superioridade definitiva de um algoritmo.

KNN x SVM

Os dois algoritmos apresentaram comportamentos diferentes. O KNN apresentou um perfil mais permissivo, classificando uma quantidade maior de vinhos regulares como bons, mas também identificando uma quantidade maior de vinhos realmente bons.

Enquanto o SVM apresentou um comportamento mais conservador, reduzindo a quantidade de falsos positivos, porém aumentando a quantidade de vinhos bons classificados incorretamente como regulares.

Dessa forma, a escolha do modelo pode depender do objetivo da aplicação. Se for mais importante evitar que bons vinhos sejam classificados como regulares, o comportamento do KNN pode ser mais interessante. Por outro lado, se o objetivo for reduzir a aprovação incorreta de vinhos regulares, o comportamento mais conservador do SVM pode ser preferível.

Importância das Variáveis na Previsão da Qualidade

Após a comparação entre KNN e SVM, foi utilizado um modelo Random Forest como ferramenta complementar para analisar a importância relativa das 11 variáveis físico-químicas na previsão da qualidade.

O objetivo dessa etapa não foi comparar o Random Forest com os modelos anteriores, mas identificar quais características apresentaram maior contribuição para as previsões realizadas pelo modelo.

Essa análise complementa os resultados obtidos na matriz de correlação, permitindo comparar as variáveis que apresentaram maior associação estatística com aquelas que apresentaram maior importância preditiva no modelo.

É importante destacar que a importância de uma variável no modelo indica sua contribuição para a previsão, não significando que exista uma relação de causa e efeito entre essa característica e a qualidade do vinho.

Importância das Variáveis

Para complementar a análise dos modelos, foi utilizado o algoritmo Random Forest com o objetivo de avaliar a importância relativa das características físico-químicas na previsão da qualidade dos vinhos.



Figura 14 – Importância das variáveis na previsão de qualidade

Os resultados indicaram que o teor alcoólico (*alcohol*) foi a variável de maior importância, apresentando valor próximo de 0,20. Em seguida, destacaram-se sulfatos (*sulphates*), dióxido de enxofre total (*total sulfur dioxide*) e acidez volátil (*volatile acidity*).

Vale ressaltar que as 4 variáveis do experimento foram selecionadas com base na análise exploratória prévia (Pearson), enquanto o Random Forest foi rodado posteriormente como validação/técnica não linear de relevância, confirmando que as variáveis *alcohol*, *sulphates* e *volatile acidity* são indispensáveis na análise.

Comparação com a Análise de Correlação

Na análise de correlação realizada anteriormente, o teor alcoólico apresentou a maior correlação positiva com a qualidade, enquanto a acidez volátil apresentou uma das relações mais fortes com a variável de qualidade. O Random Forest também identificou o álcool como a variável de maior importância. As duas análises são complementares: a correlação ajuda a identificar relações entre as variáveis, enquanto o Random Forest permite observar quais características contribuíram mais para as previsões do modelo.

Implicações para Produção

Os resultados obtidos indicam que algumas características físico-químicas apresentam maior contribuição para a classificação da qualidade dos vinhos. Entre elas, destaca-se o teor alcoólico, que apresentou a maior importância no Random Forest e a maior correlação com a qualidade na análise exploratória.

A utilização de modelos de Machine Learning pode auxiliar no processo de controle de qualidade ao fornecer uma classificação baseada nas características físico-químicas de uma amostra. Dessa forma, os modelos podem ser utilizados como uma ferramenta complementar para identificar amostras com maior ou menor probabilidade de pertencer à categoria de boa qualidade.

Entretanto, os modelos não devem substituir a avaliação realizada por especialistas. Os resultados indicam associações e capacidade de classificação, mas não permitem afirmar que alterações em uma determinada característica, isoladamente, irão necessariamente aumentar a qualidade do vinho.

Escolha do Algoritmo

Considerando os resultados obtidos, o modelo que apresentou o melhor desempenho foi o KNN utilizando quatro variáveis, com acurácia de 80,3%, AUC de 0,873 e F1-score de 0,825.

Um resultado relevante foi que a redução das variáveis não prejudicou o desempenho do KNN. Pelo contrário, o modelo utilizando quatro características apresentou desempenho superior ao KNN treinado com as 11 variáveis.

Para o SVM, entretanto, foi observado comportamento diferente: o modelo apresentou 78,6% de acurácia utilizando as 11 variáveis e 77,7% utilizando apenas quatro. Portanto, nesse caso, a redução das variáveis apresentou uma pequena perda de desempenho.

Dessa forma, considerando os resultados obtidos neste experimento, o KNN com quatro variáveis foi selecionado como o modelo de melhor desempenho.

Conclusão

Este trabalho apresentou uma análise detalhada das características físico-químicas associadas à qualidade do vinho tinto, utilizando técnicas de Análise Exploratória de Dados (EDA) e algoritmos de Aprendizado de Máquina para classificação binária das amostras em duas categorias: "Regular/Ruim" (notas < 6) e "Bom" (notas ≥ 6).

A análise exploratória revelou que o teor alcoólico (alcohol) e a acidez volátil (volatile acidity) são os fatores individuais de maior impacto na percepção de qualidade, com o álcool apresentando forte correlação positiva (0,48) e a acidez volátil apresentando correlação negativa (-0,41). A aplicação do algoritmo Random Forest reforçou esses achados, destacando também os sulfatos e o dióxido de enxofre total como variáveis de relevante poder preditivo.

No âmbito da modelagem preditiva, foram comparados os algoritmos K-Nearest Neighbors (KNN) e Support Vector Machine (SVM) em dois cenários de atributos (11 variáveis físico-químicas vs. 4 variáveis selecionadas). O modelo que obteve o melhor desempenho global foi o KNN utilizando apenas 4 variáveis, alcançando uma acurácia de 80,30%, AUC de 0,873 e F1-Score de 0,825. Observou-se que a redução dimensional para 4 atributos não apenas preservou o poder de generalização do KNN, mas eliminou ruídos, melhorando levemente suas métricas. Em contrapartida, o SVM apresentou um comportamento mais conservador nas classificações, registrando menor número de falsos positivos.

Diante dos resultados, conclui-se que os modelos de Machine Learning desenvolvidos demonstram potencial para atuar como ferramentas de suporte à decisão e auxílio ao controle de qualidade na indústria vinícola. A automação dessa triagem físico-química pode otimizar processos de produção e padronização, reduzindo custos de testes sensoriais.

Referências

CORTEZ, P.; CERDEIRA, A.; ALMEIDA, F.; MATOS, T.; REIS, J. Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, v. 47, n. 4, p. 547–553, 2009.

KAGGLE. Wine Quality Dataset. Disponível em: <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>. Acesso em: 24 ago. 2026.

SCIKIT-LEARN. scikit-learn: machine learning in Python. Disponível em: <https://scikit-learn.org/stable/>. Acesso em: 24 ago. 2026.

SCIKIT-LEARN. sklearn.neighbors.KNeighborsClassifier. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>. Acesso em: 24 ago. 2026.

SCIKIT-LEARN. sklearn.svm.SVC. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>. Acesso em: 24 ago. 2026.

SCIKIT-LEARN. sklearn.ensemble.RandomForestClassifier. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>. Acesso em: 24 ago. 2026.

SCIKIT-LEARN. sklearn.model_selection.GridSearchCV. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. Acesso em: 24 ago. 2026.

PANDAS DEVELOPMENT TEAM. pandas documentation. Disponível em: <https://pandas.pydata.org/docs/>. Acesso em: 24 ago. 2026.

MATPLOTLIB DEVELOPMENT TEAM. Matplotlib documentation. Disponível em: <https://matplotlib.org/stable/>. Acesso em: 24 ago. 2026.

WASKOM, M. seaborn: statistical data visualization. Disponível em: <https://seaborn.pydata.org/>. Acesso em: 24 ago. 2026.

Apêndice A – GitHub

github.com/IsabelaBersan/tech-challenge-fase2

Apêndice B – Vídeo YouTube

[Assistir no YouTube](#)